

1. Introdução/descrição do problema

O câncer de pele é a neoplasia mais prevalente no mundo. De acordo com a organização mundial da saúde, mais de um milhão de casos são diagnosticados anualmente, e o melanoma, tipo mais agressivo, responde por aproximadamente 75% das mortes relacionadas à doença, apesar de representar apenas uma fração dos casos. O diagnóstico precoce é o principal fator prognóstico: quando detectado em estágios iniciais, a taxa de sobrevivência em cinco anos para o melanoma supera 98%; quando detectado em estágio avançado, essa taxa cai para menos de 25%.

O diagnóstico é realizado visualmente por especialistas, com o apoio de um dermatoscópio que permite observar estruturas subsuperficiais da pele. O processo depende da experiência do clínico e apresenta variabilidade significativa mesmo entre dermatologistas experientes.

Nesse contexto, sistemas de auxílio ao diagnóstico baseados em aprendizado de máquina surgem como ferramentas complementares capazes de reduzir a variabilidade do diagnóstico e ampliar o acesso a avaliações especializadas em regiões com escassez de dermatologistas.

2. Objetivo

Esse projeto tem como objetivo desenvolver uma solução completa de classificação automática de lesões dermatológicas a partir de imagens dermatoscópicas, abrangendo todo o ciclo de vida de um sistema de inteligência artificial aplicado à saúde: da análise exploratória de dados ao deploy em produção.

Os objetivos específicos são:

Construir um pipeline de dados reprodutível, com particionamento estratificado que previna vazamento de informações entre conjuntos de treino, validação e teste;

Desenvolver e treinar um modelo de classificação multiclasse capaz de distinguir sete tipos de lesões dermatológicas presentes no dataset HAM10000;

Aplicar técnicas de interpretabilidade como: Grad-CAM, GradientSHAP e LIME para tornar as predições do modelo explicáveis e auditáveis;

Realizar uma auditoria de viés, identificando classes e subgrupos populacionais nos quais o modelo apresenta desempenho inferior e discutindo as implicações clínicas e sociais desses erros;

Operacionalizar o modelo por meio de uma API de inferência construída com FastAPI, empacotada em container Docker e com documentação automática via OpenAPI.

3. Materiais e métodos

3.1. Plataforma

O kaggle foi a principal ferramenta para o desenvolvimento, além de ser fonte dos dados provém processamento por GPU e armazenamento de dados da sessão, possibilitando a continuidade do trabalho em momentos distintos e evitando retrabalho a cada sessão.

Além disso, foi possível documentar o avanço do modelo com a geração novas versões a cada melhoria em um processo incremental.

3.2. Tratamento de dados

A base não exigiu etapas complexas de pré-processamento, o conjunto de dados estava limpo e sem dados ausentes. No entanto, o conjunto de dados possui um problema conhecido: seu extremo desbalanceamento e o número limitado de amostras.

Restando as tarefas de enriquecimento e a segmentação dos dados. O *data augmentation* será abordado na seção seguinte. Enquanto, a segmentação seguiu a proporção 85-15% para treino e teste, seguido do novo particionamento do primeiro na mesma proporção gerando conjunto de treino e validação. Note que cada novo conjunto mantém a mesma proporção de classes que dataset base. Vale destacar que um mesmo paciente pode estar em múltiplas amostras, então o ID das lesões foi considerado no particionamento para evitar vazamento de dados.

3.3. Data augmentation

Devido ao número extremo de amostras da classe 'nv', as novas imagens foram geradas com base nas classes restantes. Buscando trazer mais equilíbrio à proporção de classes.

Quanto às transformações aplicadas, inicialmente, um conjunto de diversas transformações aleatórias foram aplicadas, no entanto percebeu-se um efeito adverso que piorava o desempenho para uma arquitetura. Algumas transformações deixavam espaços vazios, que precisavam ser preenchidos de pixels pretos, o que não é indicado para modelos que segmentam a imagem em batches. Por isso, o conjunto foi limitado a apenas 3 transformações com aplicação garantida: inverter horizontalmente, verticalmente e giro 90°. A todas foram associadas a variações aleatórias nas propriedades de cores, *brightness* e *contrast*, com alcance máximo de 10%.

3.4. Modelos abordados

Para o desenvolvimento deste trabalho, foram avaliadas três abordagens fundamentadas em modelos pré-treinados: uma arquitetura baseada em Redes Neurais Convolucionais (CNN), consolidada no campo da Visão Computacional, um modelo fundamentado em Vision Transformers (ViT) e uma arquitetura híbrida que combina o processamento convolucional com a mecânica de atenção dos ViTs.

Primeiro, foi desenvolvido uma Rede Neural Convolucional (CNN) baseada na arquitetura EfficientNet-B4, utilizando a técnica de aprendizado por transferência (Transfer Learning) com ajuste fino (Fine-Tuning). A EfficientNet-B4 foi originalmente treinada na base de dados ImageNet, permitindo o aproveitamento de filtros convolucionais previamente aprendidos para extração de características visuais como bordas, texturas, formas e padrões. Essa abordagem permite que o modelo parta de um conjunto de representações visuais já consolidadas, reduzindo o tempo de treinamento e aumentando a capacidade de generalização.

O processo de treinamento foi realizado em duas fases distintas. Na primeira fase, Feature Extraction, todas as camadas convolucionais da backbone foram congeladas. Apenas a camada classificadora final foi treinada para aprender as sete classes de lesões dermatológicas presentes no conjunto de dados. Na segunda fase foi aplicado o Fine-Tuning, em que os últimos blocos da EfficientNet-B4 foram descongelados para a adaptação das representações visuais às características específicas das imagens.

Como o conjunto de dados HAM10000 apresenta um acentuado desbalanceamento entre as classes, principalmente devido a predominância de imagens da classe de *nevus melanocíticos*, foram empregadas estratégias específicas para reduzir esse problema. A primeira consistiu na utilização do WeightedRandomSampler, que realiza uma amostragem ponderada das imagens durante o treinamento, atribuindo maior probabilidade de seleção às classes menos representadas e produzindo lotes (batches) mais equilibrados. Complementarmente foram utilizadas funções de perda adaptadas ao problema de classificação desbalanceada. Entre elas destaca-se Focal Loss, que reduz a contribuição dos exemplos facilmente classificados e concentra o aprendizado nas amostras mais difíceis e pertencentes às classes minoritárias. Além disso, foi utilizado Label Smoothing para reduzir o excesso de confiança das previsões e favorecer uma melhor capacidade de generalização.

Para aumentar a diversidade das amostras e reduzir o risco de sobreajuste (overfitting), foram aplicadas diversas técnicas de Data Augmentation durante o treinamento. As imagens passaram por recortes aleatórios com redimensionamento, inversões horizontais e verticais, transformações afins envolvendo rotações, translações e escalas, além de alterações controladas de brilho, contraste e saturação. Também foi utilizado RandomErasing (Cutout), que remove aleatoriamente pequenas regiões da imagem, incentivando o modelo a considerar múltiplas regiões da lesão. Além disso, foi empregada a estratégia de Early Stopping, interrompendo automaticamente o treinamento quando a métrica de validação (Macro F1-Score) permanecia sem melhorias durante dez épocas consecutivas.

A avaliação do desempenho do modelo foi baseada principalmente no Macro F1-Score, métrica mais adequada para problemas de classificação multiclasse com dados desbalanceados. Essa métrica foi utilizada como critério para salvamento do melhor modelo durante o treinamento. Paralelamente, foi utilizado um conjunto de visualizações para monitoramento do processo de aprendizagem, incluindo gráficos das curvas de perda (Loss), acurácia, Recall e Macro F1-Score para os conjuntos de treinamento e validação, bem como a evolução da taxa de aprendizagem em escala logarítmica. Por fim, foram geradas matrizes de confusão para permitir uma análise detalhada dos erros de classificação em cada uma das sete categorias de lesões dermatológicas.

A segunda abordagem empregou o modelo pré-treinado google/vit-base-patch16-224, disponibilizado no ecossistema Hugging Face e originalmente treinado no conjunto de dados ImageNet, 1000 classes. Essa

arquitetura segmenta a imagem de entrada em patches de 16X16 pixels, projetando-os como tokens de entrada para um mecanismo de auto-atenção. Isso possibilita à rede capturar dependências e relações relacionais globais ao longo de toda a extensão espacial da imagem. Acoplada à saída do encoder, uma camada linear densa é responsável por mapear os embeddings gerados para o número de classes do problema.





Figura: Arquitetura baseada em atenção

Por fim, explorou-se um modelo híbrido com processamento em paralelo, visando integrar as vantagens complementares do aprendizado convolucional e baseado em atenção. Inicialmente, avaliou-se a combinação entre *EfficientNet* e google/vit-base-patch16-224, migrando-se posteriormente para a junção da *EfficientNet* com a *Swin Transformer Tiny* (Swin-Tiny). As características extraídas por ambas as redes são integradas por meio de uma camada de concatenação e direcionadas a uma cabeça de classificação. A função de ativação SiLU (Swish) foi adotada nos blocos intermediários da cabeça classificadora por sua convergência suave, vide a imagem abaixo.



3.5. Treino

- 3.5.1. A função de perda *CrossEntropyLoss* foi utilizada em conjunto com Class Weights calculados inversamente à frequência das classes no treino.
- 3.5.2. Os pesos das classes foram calculados considerando a frequência antes da inserção de novos dados, buscando penalizar a majoritária.
- 3.5.3. O treinamento do modelo baseado em atenção seguiu uma estratégia de *fine-tuning* em duas etapas para garantir a estabilização da rede. Inicialmente, manteve-se o *backbone* pré-treinado congelado, treinando-se apenas a cabeça classificadora por um número reduzido de épocas. Essa etapa permitiu que os novos parâmetros aleatórios da camada de saída se adaptassem à distribuição do conjunto de dados sem degradar as *features* pré-aprendidas. Em seguida, os parâmetros do *backbone* foram descongelados para o ajuste fino refinado ao longo de um número maior de épocas.

- 3.5.4. O modelo híbrido seguiu a mesma abordagem do modelo anterior. Cabe ressaltar que, nesta configuração, a extração de características é composta por dois backbones paralelos. Assim, na primeira fase, manteve-se o congelamento simultâneo dos parâmetros de ambos os extratores, treinando-se unicamente a cabeça de classificação fundida. Posteriormente, ambas as redes foram descongeladas em conjunto para o refinamento integrado ao longo das épocas finais.

3.6. Interpretabilidade

- 3.6.1. O projeto incorpora ferramentas de interpretabilidade e rastreamento experimental com o objetivo de tornar o comportamento do modelo mais compreensível e reproduzível.
- 3.6.2. As técnicas utilizadas foram: Grad-CAM (Gradient-weighted Class Activation Mapping), GradientSHAP, LIME (Local Interpretable Model-agnostic Explanations) e MLflow.
- 3.6.3. As três primeiras técnicas são utilizadas para investigar quais regiões das imagens contribuem para as decisões do modelo. O MLflow possui uma função diferente: registrar parâmetros, métricas, histórico de treinamento, modelo e artefatos associados ao experimento.
- 3.6.4. O Grad-CAM busca explicar a decisão do classificador a partir de um mapa de calor. Essa técnica utiliza a última camada convolucional para calcular a importância das features extraídas para saída. O que é de extrema importância em uma aplicação com finalidade médica, pois além de fundamentar o diagnóstico é importante localizar onde a causa está.
- 3.6.5. O GradientSHAP mostra um mapa de atribuição dos pixels, indicando quais áreas contribuíram mais para a predição da classe. As regiões em azul são de baixa contribuição para a predição, regiões em verde têm contribuição intermediária, regiões em amarelo têm alta contribuição e as áreas em vermelho têm contribuição muito alta. A técnica mostrou que o modelo aprendeu características relevantes da classe BKL (Benign Keratosis-like Lesions) com foco centralizado na lesão e pouca influência da pele ao redor. No caso da classe DF (Dermatofibroma) a técnica mostrou que o modelo acompanhou bem o contorno da lesão mas mostrou alta ativação próxima da borda circular produzida pelo dermatoscópio, isso indica que o modelo está utilizando informações da borda da imagem. A classe MEL (Melanoma) mostrou ativações bastante distribuídas, incluindo regiões da borda circular produzida pelo dermatoscópio, o que indica que o modelo está utilizando informações que não são da lesão. A classe VASC (Lesão

vascular) mostra uma região de ativação um pouco dispersa em que o modelo também está dando muita importância aos pelos próximos da lesão. Para a classe BCC (Carcinoma Basocelular) o modelo apresenta uma concentração importante na região da lesão mas também dá muita importância a borda esquerda da imagem mostrando que o modelo ainda dá muita importância a regiões fora da lesão. No caso da classe NV (Nevos melanocíticos) o GradientSHAP mostra que o modelo concentra bem sua atenção na região escura da lesão com poucas ativações periféricas. No caso da classe AKIEC (Actinic Keratoses and intraepithelial carcinoma) nota-se várias regiões altamente ativadas e uma quantidade considerável dessas regiões está fora da região principal da lesão.

- 3.6.6. O LIME é uma técnica de explicabilidade local e independente do modelo que procura identificar quais regiões da imagem contribuem positivamente ou negativamente para determinação da classificação. Diferentemente do GradientSHAP, que produz mapas contínuos de atribuição, o LIME destaca superpixels (regiões da imagem) que mais influenciaram a classificação local daquela amostra. Visualmente, os superpixels em verde indicam as regiões que mais aumentam a probabilidade da classe prevista, enquanto os em vermelho representam áreas que, se presentes, reduzem a confiança do modelo naquela classe.
- 3.6.7. De maneira geral, os resultados mostram que o modelo consegue identificar regiões relevantes em todas as classes. Entretanto, observa-se uma variação significativa na precisão espacial dessas explicações. Em algumas classes os superpixels concentram-se sobre a lesão, enquanto em outras partes da explicação estende-se para áreas adjacentes da pele saudável.
- 3.6.8. Isso indica que o modelo, embora utilize características da lesão, ainda incorpora informações do contexto em várias situações.

3.7. Seleção e avaliação de modelos

Em problemas de diagnóstico médico com alto desbalanceamento de classes, como o dataset HAM10000, onde a classe de Nevos Melanocíticos (nv) representa mais de 65% das amostras, a acurácia tradicional é uma métrica viesada. Um modelo ingênuo que preveja apenas a classe majoritária alcançaria cerca de 67% de acurácia global, mas falharia completamente na detecção de patologias críticas como o Melanoma.

Para contornar essa limitação, a Acurácia Balanceada foi definida como o critério primário de avaliação e seleção do modelo. Calculada pela média aritmética do Recall de cada uma das 7 classes:

$$\text{Balanced Accuracy} = \frac{1}{K} \sum_{i=1}^K \text{Recall}_i$$

Dessa forma, cada classe possui o mesmo peso no desempenho final do modelo, penalizando severamente falhas de detecção em classes minoritárias (como Dermatofibroma ou Lesões Vasculares).

4. Resultado

Ao comparar o desempenho das três arquiteturas sob a métrica de acurácia, observa-se uma evolução clara no aprendizado. O modelo baseado em CNN pura obteve o menor resultado (67%). A abordagem baseada exclusivamente em atenção apresentou uma melhora, alcançando aproximadamente 71%, embora com viés acentuado na classe nv. Por fim, a arquitetura híbrida destacou-se com um ganho considerável de 81%, demonstrando maior capacidade de generalização e distribuindo os acertos de forma mais equilibrada entre as demais classes.

Além do ganho mencionado, o modelo híbrido foi selecionado por apresentar o melhor desempenho no conjunto de validação com base na acurácia balanceada, métrica estabelecida previamente como critério principal de escolha. A seguir, apresentam-se as métricas registradas para os conjuntos de validação e teste:

Classe	Precision	Recall	F1-Score	Support
nv	0,9356	0,8920	0,9133	880
mel	0,5205	0,5891	0,5527	129
bkl	0,5632	0,7259	0,6343	135
bcc	0,8077	0,7778	0,7925	81
akiec	0,7674	0,6226	0,6875	53
vasc	0,7500	0,6000	0,6667	15
df	0,6429	0,6923	0,6667	13
accuracy			0,8216	1.306
macro avg	0,7125	0,7000	0,7019	1.306
weighted avg	0,8363	0,8216	0,8269	1.306

Tabela: métricas obtidas sobre o conjunto de validação.

Classe	Precision	Recall	F1-Score	Support
nv	0,9303	0,8799	0,9044	1016
mel	0,5721	0,6183	0,5943	186
bkl	0,6425	0,7209	0,6795	172

bcc	0,5870	0,8182	0,6835	66
akiec	0,6444	0,6042	0,6237	48
vasc	0,8846	0,7931	0,8364	29
df	0,5556	0,5000	0,5263	10
accuracy			0,8147	1527
macro avg	0,6881	0,7049	0,6926	1527
weighted avg	0,8271	0,8147	0,8192	1527

Tabela: métricas obtidas sobre o conjunto de testes.

A classe *nv* continua tendo desempenho predominante, o que esperado visto pelo grande número de amostras, suas métricas apresentam o maiores valores. Quanto às classes que representam lesões malignas (*mel*, *bcc* e *akiec*), todas deixam muitos casos positivos passarem, sendo *mel* a classe que tem as piores métricas. o modelo perde cerca de 41% dos casos reais de melanoma, o que representa um gargalo clínico relevante. Dentre as classes minoritárias, a *vasc* foi melhor representada do que *df*, mas o suporte para ambas é muito reduzido, por isso sua confiabilidade é baixa.

Para uma representação mais gráfica, matrizes de confusão foram geradas. É possível notar que a classe 'nv' mantém um desempenho superior, no entanto as classes restantes tiveram uma melhora na sua acurácia em relação aos outros modelos.




Figura: Matriz de confusão para o conjunto de validação




Figura: Matriz de confusão para o conjunto de testes.

A análise da matriz de confusão normalizada por classe mostra que o modelo apresenta forte capacidade de discriminação para as classes *nv* e *bcc*. Por outro lado, percebe-se que os erros relacionados a *mel* estão mais concentrados em predições errôneas de *nv*, o que é um erro grave, pois uma lesão maligna é diagnosticada como uma pinta benigna comum. Adicionalmente, nota-se que *akiec* é muito confundido com *bkl*, isso se deve ao fato das duas compartilharem muitos aspectos visuais, já que ambas as categorias tratam de Queratose, mas a primeira é maligna. Tais ambiguidades apontam para a necessidade de estratégias focadas no refino de fronteiras de decisão em trabalhos futuros.

No contexto médico, é fundamental prover a explicabilidade das decisões do modelo, o que exige não apenas a classificação diagnóstica, mas também a identificação da região de interesse da lesão. Para isso, os métodos Grad-CAM e GradientSHAP foram aplicados à última camada da CNN, gerando mapas de atribuição visual que destacam os pixels de maior relevância para a predição.




Figura: GRAD-CAM aplicado a uma amostra de cada classe.




Figura: GradientSHAP aplicado a uma amostra de cada classe.

O mapa gerado pelo GRAD-CAM parece destacar a área da lesão de forma, enquanto GradientSHAP apresenta uma representação mais dispersa. Essa divergência visual é justificada pelas características intrínsecas de cada método de IA explicável. O Grad-CAM opera sobre os mapas de características da última camada convolucional, que possuem menor resolução espacial, e utiliza interpolação para projetar a importância de volta à imagem, resultando em regiões térmicas contínuas que delimitam a lesão como um todo. Em contrapartida, o GradientSHAP atua diretamente no espaço dos pixels de entrada, aproximando os Valores de Shapley por meio de amostragens com ruído. Isso permite mapear a contribuição individual de microestruturas e variações locais de textura, originando uma representação com maior frequência espacial e aparência dispersa.

Vale salientar que a avaliação clínica detalhada dos mapas de saliência exige conhecimento dermatológico especializado. Por essa razão, a análise neste trabalho limita-se aos aspectos computacionais e de comportamento dos algoritmos de explicabilidade.

5. Considerações finais

Durante o desenvolvimento deste trabalho, buscou-se mitigar as limitações intrínsecas à tarefa e o severo desbalanceamento do conjunto de dados. O modelo final superou *baselines* ingênuas, como a predição sistemática da classe majoritária, embora ainda se situe abaixo do patamar de desempenho exigido para aplicações em cenários clínicos reais. No entanto, as estratégias adotadas para mitigar o viés do modelo apresentaram resultados promissores, promovendo um ganho efetivo na capacidade de generalização e na distribuição de acertos entre as demais classes.

O desafio decorrente da baixa frequência das classes minoritárias permaneceu como uma limitação crítica, não sendo totalmente superado mesmo com o emprego de *data augmentation* e a atribuição de pesos penalizadores. A reduzida densidade de informação associada a essas categorias comprometeu a extração de padrões mais robustos. Outro aspecto sensível diz respeito à ocorrência de falsos negativos em lesões malignas, classificadas erroneamente como benignas, o que representa um erro crítico no contexto médico. Diante disso,

trabalhos futuros devem priorizar o refino e a delimitação mais precisa das fronteiras de decisão entre tais classes.

Para trabalhos futuros, propõe-se:

- Expandir o dataset com maior diversidade étnica (fototipos cutâneos), inclusão de metadados clínicos e melhor balanceamento entre as classes.
- Aplicar algoritmos de remoção de artefatos visuais, como a atenuação de pelos sobre as lesões.
- Explorar funções de perda focais (Focal Loss), geração sintética de imagens para classes raras e arquiteturas multimodais que integrem imagens e metadados.

Levando em conta as considerações anteriores, ainda que os resultados não tenham alcançado um nível de desempenho plenamente satisfatório para uso prático, a arquitetura híbrida associada ao transfer learning revelou-se promissora. A investigação demandou a avaliação rigorosa de múltiplas abordagens, métricas e técnicas de mitigações de adversidades na busca do modelo ótimo, estabelecendo uma base para o avanço de trabalhos futuros.